

DOKUMENTACJA

1. Użyte technologie:

Aby stworzyć naszą bazę danych, skorzystaliśmy MySQL MariaDB i języka programowania R. Na początku korzystając z MySQL w programie Visual Studio Code utworzyliśmy schemat bazy danych i uzupełniliśmy ją niektórymi informacjami (pracownicy, rodzaje wycieczek). Następnie połączyliśmy naszą bazę z R i w programie Visual Studio Code napisaliśmy kod, który uzupełnia naszą bazę o losowo wygenerowane dane. Z pomocą MySQL MariaDB utworzyliśmy zapytania, które później wprowadziliśmy do Google Colab z obsługą R, aby przeanalizować dane i uzyskać raport. Na koniec stworzyliśmy dokumentację w programie Microsoft Word.

2. Lista plików projektu i opis ich zawartości:

- imie_d.csv – tabela z imionami damskimi klientów i pracowników biura turystycznego;
- imie_m.csv – tabela z imionami męskimi klientów i pracowników biura turystycznego;
- nazwiska_d.csv – tabela z nazwiskami damskimi klientów i pracowników biura turystycznego;
- nazwiska_m.csv – tabela z imionami męskimi klientów i pracowników biura turystycznego;
- schemat.png – wygenerowany schemat bazy i zależności między tabelami, ukazany na obrazku .png;
- projekt.sql – schemat bazy danych z dodanymi niektórymi danymi;
- generowanie_informacji.R – zawiera wszystkie kody, które losowo uzupełniają bazę danych o informacje;
- zapytania.sql – zawiera wszystkie surowe zapytania, których użyliśmy do stworzenia analizy danych;
- raport.rmd – plik generujący raport na podstawie analizy danych;
- raport.pdf - raport wygenerowany w PDF;
- wykres.png - wykres przedstawiający liczbę obsłużonych klientów w każdym miesiącu;
- dane_do_wykresu.csv - dane do wykresu.png;
- wykres.py - kod generujący wykres.png;
- dokumentacja_projekt.docx - zawiera informacje dotyczące sposobu uruchamiania plików, schemat bazy danych oraz jej opis.

Wszystkie pliki .csv pochodzą ze strony Głównego Urzędu Statystycznego (GUS).

3. Kolejność i sposób uruchamiania plików, aby uzyskać gotowy projekt:

1. W pierwszej kolejności pobieramy wszystkie pliki i dodajemy je do jednego folderu (istotne są pliki z rozszerzeniem .csv).
2. Otwieramy **schemat.png**.
3. Otwieramy **projekt.sql** (plik w Visual Studio Code).
4. Otwieramy **generowanie_informacji.R** (plik w RStudio, uruchomiamy cały kod zawarty w pliku przyciskiem „Run all”) Niestety, uruchamianie kodu może chwilę potrwać.
5. Otwieramy **zapytania.sql** (plik w Visual Studio Code) – aby uruchomić poszczególne zapytania należy zaznaczyć zapytanie, które nas interesuje i kliknąć na klawiaturze „CTRL” + dwa razy ”e”.
6. Uruchamiamy **raport.pdf**.

4. Schemat projektu bazy danych:

Aby opracować schemat projektu naszej bazy danych, zaczęliśmy od spisania listy informacji, które chcieliśmy umieścić w bazie. Następnie podzieliliśmy je na tabele, których struktury rozplanowaliśmy wcześniej. Kolejnym krokiem było rozpisanie zależności funkcyjnych dla każdej relacji. Na koniec utworzyliśmy odpowiednie tabele w Visual Studio Code, korzystając z funkcji CREATE TABLE. W trakcie tego procesu dodawaliśmy na bieżąco również zależności funkcyjne oraz klucze w każdej tabeli.

5. Lista zależności funkcyjnych między kolumnami w tabelach:

Nazwa tabeli	Spis zależności funkcyjnych między kolumnami
Pracownicy (przechowuje dane pracowników)	- id_pracownik → imie, nazwisko, email, numer_telefonu, pensja, data_zatrudnienia (każda wartość id_pracownik jednoznacznie określa imię, nazwisko, nr telefonu, pensję oraz datę zatrudnienia pracownika w biurze) - email → imie, nazwisko, numer_telefonu
Rodzaje_wycieczek (przechowuje rodzaje wycieczek oferowanych przez firmę)	- id_rodzaj → nazwa, kierunek, opis, cena (każda wartość id_rodzaj jednoznacznie określa nazwę, kierunek, opis oraz cenę rodzaju wyjazdu)
Wyjazdy (przechowuje rekordy wyjazdów zorganizowanych przez firmę od początku działalności)	- id_wyjazd → id_rodzaj, id_pracownik, data_wyjazdu, data_powrotu, koszt_calkowity, liczba_uczestnikow (każda wartość id_wyjazdu jednoznacznie określa rodzaj wycieczki, pracownika sprzedającego wycieczkę, datę wyjazdu oraz powrotu, koszt całkowity oraz liczbę uczestników)

Koszty_organizacji (przechowuje koszty organizacji wycieczek)	- id_koszt → id_wyjazd, opis_kosztu, koszt (każda wartość id_kosztu jednoznacznie określa id wyjazdu, opis kosztów oraz koszt) - id_wyjazd → koszt
Transakcje_finansowe (przechowuje rekordy transakcji finansowych realizowanych przez firmę)	- id_transakcja → id_wyjazd, data_transakcji, kwota, typ_transakcji, opis (każda wartość id_transakcja jednoznacznie określa id wyjazdu, datę transakcji, kwotę, typ oraz opis transakcji przychodzącej lub wychodzącej z biura)
Klienci (przechowuje dane klientów biura)	- id_klient → imie, nazwisko, email, numer_telefonu, adres, data_urodzenia (każda wartość id_klient jednoznacznie określa imię, nazwisko, email, numer telefonu, adres i datę urodzenia klienta) - email → imie, nazwisko, numer_telefonu (każda wartość email określa imię, nazwisko i numer telefonu klienta biura)
Kontakt_bliscy (przechowuje dane bliskich klientów w ramach kontaktu w przypadku wystąpienia losowej sytuacji)	- id_kontakt → id_klient, imie, nazwisko, numer_telefonu, relacja (każda wartość id_kontakt jednoznacznie określa imię, nazwisko, numer telefonu oraz relację bliskiego klienta biura)

6. Uzasadnienie, że baza jest w EKNF.

EKNF (ang. Elementary Key Normal Form) oznacza, że baza danych jest znormalizowana do 3NF (ang. 3 Normal Form), ale jeszcze nie spełnia bardziej restrykcyjnych kryteriów BCNF (ang. Boyce-Codd Normal Form). Baza jest w EKNF, jeśli jej tabele spełniają następujące wymagania: kolumny niebędące częścią klucza głównego muszą zależeć od klucza głównego tabeli (kryterium dla 3NF), ale mogą pojawiać się zależności, w których determinant jest kluczem kandydującym (niedopuszczalne dla BCNF). W naszej każdej tabeli, jak widać w opisie zależności funkcyjnych w powyższym punkcie, każda kolumna nieposiadająca klucza jest w pełni zależna od klucza głównego danej tabeli (każda wartość klucza jednoznacznie określa resztę wartości w kolumnach), a także np. z zależności funkcyjnych w tabeli Pracownicy można wywnioskować, że również email może być determinantem jako klucz kandydujący (ponieważ każdy pracownik ma unikalny adres email, co oznacza, że jednoznacznie identyfikuje on każdego pracownika). Dlatego nasze tabele spełniają EKNF, co oznacza, że nasza baza danych również znajduje się w EKNF.

7. Co sprawiło nam najwięcej trudności podczas realizacji projektu?

Podczas realizacji projektu napotkaliśmy kilka trudności. Jednym z problemów była instalacja środowiska R, która sprawiła nam niemało kłopotów i poświęciliśmy wiele czasu na jego konfigurację, aby działał prawidłowo. Z kolejną trudnością mierzyliśmy się podczas tworzenia tabel i prób wprowadzania w nich zmian, ponieważ błędy ciężko było skorygować - z powodu zależności funkcyjnych między tabelami, jeśli zrobiliśmy błąd w jednej, trzeba było później usuwać wszystkie tabele z nią związane i tworzyć je na nowo, co definitywnie było uciążliwe i przysporzyło nam wiele problemów na końcowych etapach tworzenia bazy. Napotkaliśmy także problemy przy generowaniu końcowego raportu w PDF-ie za pomocą RStudio. Nie ukrywamy, że kłopotliwa była również dla nas data oddania projektu, która jest bliska terminowi sesji, co na pewno miało wpływ na naszą ogólną pracę.